

Evrişimsel Sinir Ağları Kullanarak Göğüs Röntgen Görüntülerinden COVID-19 Tespiti

İbrahim Biner
Yazılım Mühendisliği
Kocaeli Üniversitesi
ibrahimbiner30@gmail.com
220229049

Buse Nur Baş
Yazılım Mühendisliği
Kocaeli Üniversitesi
busenurb277@gmail.com
220229015

Abstract—2020 yılının başlarında dünya genelinde ortaya çıkan COVID-19, insan sağlığı üzerinde ciddi tehditler oluşturmıştır. Bu çalışma, COVID-19'un göğüs röntgeni görüntülerinden tespiti için derin öğrenme tabanlı modellerin kullanılmasını amaçlamaktadır. Transfer learning teknikleriyle çeşitli CNN mimarileri değerlendirilmiş, elde edilen sonuçlar literatürdeki bir makale ile karşılaştırılmıştır.

Index Terms—COVID-19, Derin Öğrenme, CNN, Göğüs Röntgeni, Transfer Learning

I. GİRİŞ

2020 yılının başlarında dünya genelinde ortaya çıkan ve hızla yayılarak küresel bir pandemi haline gelen COVID-19 (Coronavirus Disease 2019), insan sağlığı üzerinde ciddi tehditler oluşturmuş ve milyonlarca kişinin yaşamını etkilemiştir. Solunum yolu hastalıklarına yol açan bu virüs, özellikle yaşlı bireyler ve kronik hastalığı olan kişilerde ciddi komplikasyonlara, hatta ölüme sebep olabilmektedir. COVID-19'un hızlı ve güvenilir şekilde teşhis edilmesi, hem hasta bireylerin tedavi süreçlerinin erken başlatılması hem de salgının yayılımının önlenmesi açısından kritik bir öneme sahiptir.

Geleneksel tanı yöntemlerinden biri olan RT-PCR (Real-Time Polymerase Chain Reaction) testi, COVID-19'un varlığını doğrudan tespit edebilmekle birlikte; testin sonuçlanması saatler alabilmekte, maliyetli olmakta ve bazı durumlarda yanlış negatif sonuçlar doğurabilmektedir. Bu nedenle, özellikle düşük kaynaklı bölgelerde, alternatif ve tamamlayıcı tanı yöntemlerine ihtiyaç duyulmaktadır.

Bu bağlamda, tıbbi görüntüleme tekniklerinden biri olan göğüs röntgeni (Chest X-Ray), COVID-19'un hızlı şekilde taranmasında oldukça önemli bir rol üstlenmektedir. COVID-19'a bağlı zatürre vakalarında, X-ray görüntülerinde karakteristik akciğer lezyonları gözlemlenebilir. Ancak bu görüntülerin doğru yorumlanması deneyimli radyologlar gerektirir ve hata payı içerir. Bu zorlukların üstesinden gelmek amacıyla, yapay zeka tabanlı yaklaşımlar medikal görüntü analizinde etkili çözümler sunmaya başlamıştır.

Son yıllarda derin öğrenme (Deep Learning), özellikle evrişimsel sinir ağları (Convolutional Neural Networks – CNN) sayesinde görüntü işleme alanında çığır açıcı gelişmeler kaydetmiştir. CNN modelleri, bir görüntüdeki kenar, şekil, doku gibi özellikler otomatik olarak öğrenerek sınıflandırma

yapabilir. Bu avantajı sayesinde CNN mimarileri, COVID-19 gibi solunum yolu hastalıklarının görüntü temelli tespitinde kullanılmaya başlanmıştır.

Bu projede, göğüs röntgeni görüntülerinden COVID-19, Normal ve Pneumonia sınıflarının tespiti için derin öğrenme mimarileri kullanılmıştır. Transfer learning (aktarım öğrenmesi) tekniği ile önceden büyük veri kümeleri üzerinde eğitilmiş modeller (VGG16, VGG19, NASNet-Large, vb.) kullanılarak eğitim süreci hızlandırılmış ve performans artırılmıştır. Transfer learning, özellikle sınırlı sayıda medikal veri bulunan durumlarda yaygın olarak tercih edilen bir yaklaşımdır. Bu yöntemde, modelin erken katmanları sabitlenip sadece üst katmanlar yeniden eğitilerek hem zaman kazanılır hem de genelleme gücü yüksek modeller elde edilir.

Proje sürecinde kullanılan modeller çeşitli hiperparametrelerle eğitilmiş, veri artırma (data augmentation) teknikleriyle overfitting riski azaltılmış ve model başarımı doğruluk (accuracy), F1-skoru, hassasiyet (precision), duyarlılık (recall) gibi metriklerle değerlendirilmiştir. Ayrıca kullanılan modellerin çıktıları Antonios Makris ve arkadaşlarının yayımladığı “COVID-19 detection from chest X-Ray images using Deep Learning and Convolutional Neural Networks” başlıklı akademik makalenin sonuçlarıyla karşılaştırılmıştır.

Bu çalışma, hem transfer learning yaklaşımıyla derin öğrenme uygulamalarının sağlık alanında etkili bir şekilde nasıl kullanılabileceğini göstermek hem de farklı CNN mimarilerinin COVID-19 teşhisi üzerindeki performanslarını karşılaştırmalı olarak değerlendirmek amacıyla gerçekleştirilmiştir.

II. MATERYAL VE METOT

A. Convolutional Neural Networks (CNN) Nedir?

Convolutional Neural Networks (CNN), özellikle görüntü verileri üzerinde yüksek başarıyla çalışan bir derin öğrenme mimarisidir. Görüntü sınıflandırma, nesne tanıma ve tıbbi görüntü analizi gibi alanlarda yaygın olarak kullanılmaktadır. CNN'ler, görüntüdeki yerel özellikler (kenar, köşe, doku gibi) çıkarılabilen konvolüsyon katmanları ile çalışır. Bu katmanlar, görüntü üzerinde filtreler gezdirerek özellik haritaları (feature maps) üretir. Devamında gelen pooling katmanları ile boyut küçültülür, ardından tam bağlı (fully connected) katmanlarla sınıflandırma işlemi gerçekleştirilir.

B. Transfer Learning Nedir?

Transfer learning (aktarım öğrenmesi), önceden büyük veri kümeleri (örneğin ImageNet) üzerinde eğitilmiş bir modelin, farklı ama benzer bir problem üzerinde yeniden kullanılmasıdır. Bu yöntemde modelin alt katmanları sabitlenirken, üst katmanlar yeniden eğitilir.

C. Kullanılan Ortam ve Kütüphaneler

Tüm modeller Google Colab üzerinde GPU desteği ile Python ve TensorFlow/Keras kullanılarak geliştirilmiştir.

D. Veri Artırma (Data Augmentation)

Aşağıdaki kod bloğu ile eğitim verisi çeşitlendirilmiştir:

```
train_datagen = ImageDataGenerator(
    rescale=1./255,
    rotation_range=15,
    width_shift_range=0.1,
    height_shift_range=0.1,
    zoom_range=0.1,
    horizontal_flip=True,
    fill_mode='nearest'
)
```

E. Kullanılan Modeller ve Yöntemler

Projede VGG16, VGG19, Xception ve ResNet152V2 modelleri transfer learning yöntemi ile yeniden eğitilmiştir. Çıkış katmanlarında GlobalAveragePooling2D, Dense, Dropout ve Softmax kullanılmıştır.

F. Parametreler ve Eğitim Stratejileri

Kullanılan hiperparametreler:

- Batch size: 32
- Epochs: 15
- Learning rate: 0.0001

Adam ve SGD optimizasyon algoritmaları karşılaştırılmış; SGD ile doğruluk oranı yaklaşık %3.17 daha yüksek olmuştur.

G. Early Stopping

Aşağıdaki kod ile aşırı öğrenme önlenmiştir:

```
early_stop = EarlyStopping(monitor='val_loss',
    patience=3,
    restore_best_weights=True)
```

H. Performans Ölçütleri

Model performansı aşağıdaki formüllerle hesaplanmıştır:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

$$\text{Specificity} = \frac{TN}{TN + FP} \quad (5)$$

Burada TP : True Positive, TN : True Negative, FP : False Positive, FN : False Negative değerlerini ifade eder.

III. VERİ SETİ

Bu çalışmada COVID-19, Normal ve Pneumonia hastalıklarının sınıflandırılması hedeflenmiştir. Kullanılan veri seti, COVID-19 Radiography Database'dir.

A. Sınıf Sayısı

Veri setinde üç sınıf bulunmaktadır: COVID-19, Normal ve Pneumonia. Her sınıftan eşit sayıda görüntü seçilmiştir.

B. Eğitim/Doğrulama Ayrımı

TABLE I
EĞİTİM VE DOĞRULAMA GÖRÜNTÜ SAYILARI

Sınıf	Eğitim	Doğrulama
COVID-19	1000	200
Normal	1000	200
Pneumonia	1000	200
Toplam	3000	600

C. Görüntü Boyutları

Tüm görüntüler 224x224 piksel boyutuna yeniden boyutlandırılmıştır.

D. Google Drive Üzerinden Veri Yükleme

Veri, Google Drive'a yüklenip aşağıdaki kodla bağlanılmıştır:

```
from google.colab import drive
drive.mount('/content/drive')
```

E. Platform ve Ortam

Tüm eğitim işlemleri Google Colab ortamında GPU desteğiyle yürütülmüştür.

IV. DENEYSEL SONUÇLAR

Bu bölümde, kullanılan derin öğrenme modellerinin sınıflandırma performansları değerlendirilmiştir. Modeller; COVID-19, Normal ve Pnömoni sınıflarını ayırt etme konusundaki başarıları açısından doğruluk (accuracy), precision, recall (duyarlılık), F1-score ve specificity (özgüllük) gibi metriklerle karşılaştırılmıştır.

A. ResNet152V2

ResNet152V2 modeli, bu çalışmada en yüksek doğruluğu sağlayan model olmuştur. Model ilk olarak Adam optimizasyon algoritması ile eğitilmiş ve %93.83 doğruluk elde edilmiştir. Ancak, daha sonra Stochastic Gradient Descent (SGD) ile yeniden eğitildiğinde doğruluk oranı %97.00'ye yükselmiştir. Bu sonuç, SGD'nin bu problem için daha stabil ve etkili bir öğrenme sağladığını göstermektedir.

Modelin dengeli yapısı, üç sınıf için de yüksek özgüllük ve F1 skorları sağlamıştır. Özellikle pnömoni sınıfında %100 başarı göstererek hastalığın doğru tespitinde son derece etkilidir.

TABLE II
RESNET152V2 PERFORMANS DEĞERLERİ

Sınıf	Precision	Recall	F1-score	Specificity
COVID-19	0.9642	0.9450	0.9545	0.9825
Normal	0.9465	0.9650	0.9554	0.9750
Pneumonia	1.0000	1.0000	1.0000	1.0000
Genel Doğruluk: 97.00%				

B. VGG16

VGG16 modeli, genel doğruluk açısından oldukça başarılıdır ve %96.33 doğruluk oranı elde etmiştir. Özellikle pnömoni sınıfında %99.75 özgüllük ve %100 duyarlılık (recall) ile dikkat çekmektedir.

TABLE III
VGG16 PERFORMANS DEĞERLERİ

Sınıf	Precision	Recall	F1-score	Specificity
COVID-19	0.9590	0.9350	0.9468	0.9800
Normal	0.9363	0.9550	0.9455	0.9675
Pneumonia	0.9950	1.0000	0.9975	0.9975
Genel Doğruluk: 96.33%				

C. VGG19

VGG19 modeli, %91.17 doğruluk ile orta seviyede bir başarı göstermiştir. COVID-19 sınıfında yüksek duyarlılık elde edilmesine rağmen, "Normal" sınıfındaki düşük Recall değeri modelin performansını düşürmüştür.

TABLE IV
VGG19 PERFORMANS DEĞERLERİ

Sınıf	Precision	Recall	F1-score	Specificity
COVID-19	0.8267	0.9300	0.8753	0.9025
Normal	0.9200	0.8050	0.8587	0.9650
Pneumonia	1.0000	1.0000	1.0000	1.0000
Genel Doğruluk: 91.17%				

Bu model, diğerlerine kıyasla daha düşük genel doğruluk sağlasa da, pnömoni tespitinde yine yüksek başarı göstermiştir.

D. Xception

Xception modeli %94.33 doğruluk oranına ulaşarak dengeli bir başarı göstermiştir. COVID-19 sınıfında %95.50 Recall ile hastalığı doğru tespit etmede etkili olmuştur.

TABLE V
XCEPTION PERFORMANS DEĞERLERİ

Sınıf	Precision	Recall	F1-score	Specificity
COVID-19	0.8843	0.9550	0.9183	0.9375
Normal	0.9511	0.8750	0.9115	0.9775
Pneumonia	1.0000	1.0000	1.0000	1.0000
Genel Doğruluk: 94.33%				

Model, özellikle pnömoni sınıfında %100 başarı göstermiş, ancak "Normal" sınıfındaki Recall düşük kalmıştır.

TABLE VI
TÜM MODELLERİN KARŞILAŞTIRMALI PERFORMANSI

Model	Sınıf	Precision	Recall	F1-score	Spec.
3*ResNet152V2	COVID-19	0.9642	0.9450	0.9545	0.9825
	Normal	0.9465	0.9650	0.9554	0.9750
	Pneu.	1.0000	1.0000	1.0000	1.0000
3*VGG16	COVID-19	0.9590	0.9350	0.9468	0.9800
	Normal	0.9363	0.9550	0.9455	0.9675
	Pneu.	0.9950	1.0000	0.9975	0.9975
3*VGG19	COVID-19	0.8267	0.9300	0.8753	0.9025
	Normal	0.9200	0.8050	0.8587	0.9650
	Pneu.	1.0000	1.0000	1.0000	1.0000
3*Xception	COVID-19	0.8843	0.9550	0.9183	0.9375
	Normal	0.9511	0.8750	0.9115	0.9775
	Pneu.	1.0000	1.0000	1.0000	1.0000

E. Genel Değerlendirme

ResNet152V2, hem yüksek doğruluk (%97.00) hem de sınıflar arası dengeli performans ile en iyi sonucu vermiştir. VGG16, pnömoni sınıfında neredeyse kusursuz sonuçlar üretmiş ve genel doğruluk açısından ikinci sırada yer almıştır. VGG19, COVID-19 sınıfında başarılı olsa da "Normal" sınıftaki düşük Recall değeri nedeniyle genel doğruluğu daha düşüktür. Xception, genel olarak yüksek performans gösterse de özellikle "Normal" sınıfındaki Recall düşüklüğü dikkat çekicidir.

F. Model Performansları

Tüm modellerin Confusion Matrix görselleri ve epoch bazında doğruluk/kayıp (accuracy/loss) değişim grafiklerine raporun Ekler bölümünde yer verilmiştir.




Fig. 1. VGG16 Model Performance




Fig. 2. VGG19 Model Performance



Fig. 3. ResNet152V2 Model Performance



Fig. 4. Xception Model Performance

G. Confusion Matrix




Fig. 5. VGG16 Confusion Matrix




Fig. 6. VGG19 Confusion Matrix




Fig. 7. ResNet152V2 Confusion Matrix




Fig. 8. Xception Confusion Matrix

V. MAKALE İLE KARŞILAŞTIRMA

A. Literatür İncelemesi

COVID-19 pandemisiyle birlikte, göğüs röntgeni (CXR) görüntüleri üzerinden otomatik teşhis sistemlerinin geliştirilmesi yoğun ilgi görmüştür. Yapılan birçok çalışma, Convolutional Neural Networks (CNN) ve transfer öğrenme yaklaşımlarının COVID-19'un erken teşhisi için oldukça etkili olduğunu göstermektedir. Örneğin, Apostolopoulos ve Mpesiana (2020), VGG19 tabanlı bir model ile %93.48 doğruluk elde etmiş; Hemdan et al. (2020) ise COVID-Net gibi derin mimarilerle yüksek başarı oranları bildirmiştir.

Bu bağlamda, Antonios Makris'in çalışması (Makris et al., 2020), transfer öğrenme yaklaşımını kullanarak çeşitli önceden eğitilmiş modellerin performanslarını karşılaştırmalı olarak incelemiş ve CXR görüntülerinden COVID-19, Normal ve Pnömoni sınıflarını ayırt etmeyi amaçlamıştır.

B. Kullanılan Yöntemlerin Karşılaştırılması

Her iki çalışmada da transfer learning ve CNN mimarileri kullanılmıştır. Bu çalışmada ImageNet üzerinde önceden eğitilmiş VGG16, VGG19, Xception ve ResNet152V2 mimarileri tercih edilmiştir. Bu modellerin sınıflandırma katmanları çıkarılmış, yerine yeni katmanlar eklenerek yalnızca üst katmanlar eğitilmiştir.

Makris'in çalışmasında da transfer learning uygulanmış, ancak fine-tuning ile ilgili detay verilmemiştir. Bu fark, modellerin performansında etkili olabilir.

Bu çalışmada kullanılan bazı hiperparametreler:

- Batch size: 32
- Epochs: 15
- Learning rate: 0.0001
- Optimizasyon algoritması: Adam (VGG16, VGG19, Xception), SGD (ResNet152V2)

ResNet152V2 modelinde SGD kullanımı, doğruluğu %93.83'ten %97.00'ye çıkarmıştır. Bu durum, optimizasyon stratejilerinin başarı üzerindeki etkisini ortaya koymaktadır.

C. Sonuçların Karşılaştırılması

Aşağıda bu çalışmanın sonuçları ile Makris'in çalışmasındaki sonuçlar tabloda karşılaştırılmıştır:

TABLE VII
MODELLERE GÖRE PRECISION KARŞILAŞTIRMASI

Model	Sınıf	Bizim	Makris
3*VGG16	covid	0.9590	0.96
	normal	0.9363	0.95
	pneumonia	0.9950	0.95
3*VGG19	covid	0.8267	1.00
	normal	0.9200	0.95
	pneumonia	1.0000	0.95
3*Xception	covid	0.8843	1.00
	normal	0.9511	0.88
	pneumonia	1.0000	0.61
3*ResNet152V2	covid	0.9642	1.00
	normal	0.9465	0.95
	pneumonia	1.0000	0.46

TABLE VIII
MODELLERE GÖRE RECALL (SENSITIVITY) KARŞILAŞTIRMASI

Model	Sınıf	Bizim	Makris
3*VGG16	covid	0.9350	0.96
	normal	0.9550	1.00
	pneumonia	1.0000	0.91
3*VGG19	covid	0.9300	0.92
	normal	0.8050	1.00
	pneumonia	1.0000	0.91
3*Xception	covid	0.9550	0.62
	normal	0.8750	0.70
	pneumonia	1.0000	1.00
3*ResNet152V2	covid	0.9450	0.12
	normal	0.9650	0.90
	pneumonia	1.0000	0.95

TABLE IX
MODELLERE GÖRE F1-SCORE KARŞILAŞTIRMASI

Model	Sınıf	Bizim	Makris
3*VGG16	covid	0.9468	0.96
	normal	0.9455	0.98
	pneumonia	0.9975	0.93
3*VGG19	covid	0.8753	0.96
	normal	0.8587	0.98
	pneumonia	1.0000	0.93
3*Xception	covid	0.9183	0.76
	normal	0.9115	0.78
	pneumonia	1.0000	0.76
3*ResNet152V2	covid	0.9545	0.21
	normal	0.9554	0.92
	pneumonia	1.0000	0.62

TABLE X
MODELLERE GÖRE SPECIFICITY KARŞILAŞTIRMASI

Model	Sınıf	Bizim	Makris
3*VGG16	covid	0.9800	0.98
	normal	0.9675	0.98
	pneumonia	0.9975	0.98
3*VGG19	covid	0.9025	1.00
	normal	0.9650	0.98
	pneumonia	1.0000	0.95
3*Xception	covid	0.9375	1.00
	normal	0.9775	0.95
	pneumonia	1.0000	0.69
3*ResNet152V2	covid	0.9825	1.00
	normal	0.9750	0.97
	pneumonia	1.0000	0.45

TABLE XI
MODEL BAZINDA GENEL ACCURACY KARŞILAŞTIRMASI

Model	Bizim Accuracy	Makris Accuracy
VGG16	0.9633	0.9588
VGG19	0.9117	0.9503
Xception	0.9433	0.7647
ResNet152V2	0.9700	0.6176

D. Değerlendirme ve Sonuç

Makris'in çalışmasına kıyasla, özellikle Xception ve ResNet152V2 modellerinde bu çalışmanın daha başarılı olduğu görülmektedir. Örneğin, Makris'in Xception modeli %76.47 doğruluk elde etmişken, bu çalışmada %94.33'e ulaşılmıştır. ResNet152V2 için bu fark daha da çarpıcıdır: %61.76'dan %97.00'ye.

Bu farklar, optimizasyon algoritmalarının seçimi (özellikle SGD) ve veri artırma tekniklerinin model başarımı üzerinde doğrudan etkili olduğunu göstermektedir.

Sonuç olarak, her iki çalışmada da transfer learning yöntemi başarıyla uygulanmış, ancak bu çalışmadaki hiperparametre seçimleri ve eğitim stratejileri daha üstün sonuçlar elde edilmesini sağlamıştır.

VI. TARTIŞMA

Bu çalışmada, transfer öğrenme tabanlı dört farklı CNN mimarisi olan VGG16, VGG19, Xception ve ResNet152V2 modelleri kullanılarak COVID-19, normal ve pnömoni sınıflarının göğüs röntgeni görüntüleri üzerinden sınıflandırılması gerçekleştirilmiştir. Modeller yalnızca önceden eğitilmiş ağırlıklarla kullanılmış, fine-tuning işlemi uygulanmamıştır. Bu sayede transfer öğrenmenin doğrudan etkisi değerlendirilebilmiştir.

Modellerin genel doğruluk performansları aşağıda verilmiştir:

- **ResNet152V2:** 0.9700
- **VGG16:** 0.9633
- **Xception:** 0.9433
- **VGG19:** 0.9117

ResNet152V2, en yüksek doğruluk değerine ulaşmış ve tüm sınıflarda dengeli bir performans sergilemiştir. Bu modelin derin ve rezidual yapısı, öğrenme sırasında bilgi kaybını

minimize ederek karmaşık desenleri başarılı bir şekilde ayırt etmesini sağlamıştır. Her ne kadar fine-tuning yapılmamış olsa da, önceden eğitilmiş katmanlar veriye yüksek düzeyde uyum sağlamıştır.

VGG16 modeli, %96.33 doğruluk oranıyla ikinci sırada yer almış ve özellikle COVID-19 ve pnömoni sınıflarında yüksek F1-score değerlerine ulaşmıştır. Bu başarı, modelin sade ve düzenli yapısının küçük veri setleriyle etkili çalışmasından kaynaklanmaktadır.

Xception modeli, %94.33 doğruluk ile tatmin edici bir performans sergilemiştir. Özellikle COVID-19 sınıfındaki yüksek recall değeri, modelin pozitif vakaları doğru şekilde tespit etme yeteneğini ortaya koymaktadır. Bu modelde kullanılan depthwise separable convolution yapısı, parametre sayısını azaltırken önemli özellikleri yakalamada etkili olmuştur.

VGG19 ise diğer modellere göre daha düşük bir doğruluk (%91.17) sergilemiştir. Bu modelin derinliği VGG16'ya kıyasla fazla olsa da, fine-tuning yapılmaması ve sınırlı veriyle eğitim, modelin bazı sınıflarda genelleme yapma kabiliyetini azaltmıştır. Ayrıca derin katmanların eğitilmeden kullanılması, öğrenilen özelliklerin yeni veriye tam uyumlu olmamasına neden olmuş olabilir.

Donanım açısından bakıldığında, derin modellerin (ResNet152V2, Xception) daha fazla bellek ve işlem süresi gerektirdiği gözlemlenmiştir. Özellikle Google Colab gibi sınırlı kaynak sunan ortamlarda bu durum eğitim süresini uzatmış ve *batch size* gibi parametrelerin dikkatli seçilmesini zorunlu kılmıştır.

Gelecek Çalışmalar İçin Öneriler

- Fine-tuning uygulanarak, modelin orta ve alt katmanlarındaki filtrelerin veri setine daha iyi uyum sağlaması sağlanabilir
- NOT: VGG19 Modeli ile fine-tuning işlemi denendi fakat alınan sonuçlar normal sonuçlar ile karşılaştırıldığında daha kötü bir performans gösterdi.
- Veri setinin daha dengeli hale getirilmesi, sınıflar arası öğrenme farklarını azaltabilir.
- Hiperparametre ayarlamaları (learning rate, batch size, optimizör tipi vb.) ile performans daha da artırılabilir.
- Model topluluklama (*ensemble*) yaklaşımlarıyla, farklı mimarilerin güçlü yönleri birleştirilerek daha yüksek doğruluk ve kararlılık sağlanabilir.

Sonuç olarak, yalnızca önceden eğitilmiş modellerin kullanılmasıyla dahi oldukça yüksek doğruluk oranlarına ulaşılmıştır. Bu durum, transfer öğrenmenin medikal görüntü analizi gibi alanlarda güçlü bir başlangıç noktası olduğunu göstermektedir.

REFERENCES

- [1] A. Makris, A. Tserpes, and D. Varvarigou, "COVID-19 Detection from Chest X-Ray Images Using Deep Learning and Convolutional Neural Networks," *Pattern Recognition Letters*, vol. 152, pp. 27–33, 2021, doi: 10.1016/j.patrec.2021.09.003.
- [2] J. Cohen, P. Morrison, and L. Dao, "COVID-19 Image Data Collection," *arXiv preprint arXiv:2003.11597*, 2020. [Online]. Available: <https://arxiv.org/abs/2003.11597>
- [3] K. Ozturk, M. Talo, E. A. Yildirim, U. B. Baloglu, O. Yildirim, and U. R. Acharya, "Automated detection of COVID-19 cases using deep neural networks with X-ray images," *Computers in Biology and Medicine*, vol. 121, p. 103792, 2020, doi: 10.1016/j.combiomed.2020.103792.
- [4] M. Rahimzadeh and A. Attar, "A modified deep convolutional neural network for detecting COVID-19 and pneumonia from chest X-ray images based on the concatenation of Xception and ResNet50V2," *Informatics in Medicine Unlocked*, vol. 19, 2020, doi: 10.1016/j.imu.2020.100360.
- [5] A. Apostolopoulos and T. Bessiana, "COVID-19: automatic detection from X-ray images utilizing transfer learning with convolutional neural networks," *Physical and Engineering Sciences in Medicine*, vol. 43, pp. 635–640, 2020, doi: 10.1007/s13246-020-00865-4.
- [6] COVID-19 Radiography Database (Kaggle)
- [7] Papers With Code – COVID-19 Chest X-ray Classification
- [8] NIH Chest X-ray Dataset
- [9] TensorFlow Model Garden